

RSNet: Recursive Scaling Network

Sinyal Verilerinde İlişkisel Örüntüleri Yakalamak İçin Hafif Bir Hiyerarşik Mimari

RSNet Nedir?

RSNet, sekans verilerini işlemek üzere tasarlanmış, hafif, hiyerarşik ve sinyal odaklı bir sinir ağı mimarisidir. Zaman adımlarını sırayla okumak yerine, ikili ağaç (binary tree) mantığıyla veriyi eşleştirerek katman katman sıkıştırır.

Sıralı verileri işleyen mevcut mimariler — RNN, LSTM, GRU — her bir zaman adımını sırayla işler. Bu sekansiyel yapı $O(N)$ derinlikte bir gradyan yolu oluşturur; dizi uzadıkça gradyan ya kaybolur ya patlar. LSTM kapı mekanizmalarıyla bu sorunu hafifletir ama tamamen çözmez. Transformer ise tüm çiftleri birbirine bağlayarak $O(N^2)$ hesaplama maliyeti üretir.

RSNet bu iki yaklaşımdan farklı bir yol izler: ikili ağaç yapısında hiyerarşik indirgeme. N elemanlı bir diziyi her seviyede yarılayarak $O(\log_2 N)$ derinlikte tek bir temsil vektörüne indirger. Sekansiyel bağımlılık yoktur; gradyan yolu logaritmik kısalmır.

RSNet genel amaçlı bir sekans modeli değildir. Çarpımsal ilişkilerin ve ardışık noktalar arası oransal farkların baskın olduğu sinyal verilerinde — sensör, radar, biyomedikal, finansal volatilité — özelleşmiş bir mimaridir. Amacı her şeyi yapmak değil, belirli bir problemi hızlı ve az parametreyle çözmektir.

RSBlock: Temel Hesaplama Birimi

RSNet'in en küçük yapı taşı RSBlock'tur. İki girdi vektörünü (X_1, X_2) alır, aralarındaki çarpımsal ilişkiyi çıkarır ve tek bir çıktı vektörü üretir. Klasik toplamsal veya dot-product (iç çarpım) yöntemleri yerine çarpımsal ve oransal bir formül kullanır.

Formül altı adımdan oluşur:

1. Lineer Projeksiyon: $Y1 = X1 @ W1$, $Y2 = X2 @ W2$ (matris çarpımı)
2. Çarpımsal Füzyon: $F1 = Y1 \odot Y2$ (eleman bazlı çarpım)
3. Dinamik Ölçekleme: $F2 = F1 / (|Y1 + Y2| + \epsilon)$
4. Aktivasyon: $X3 = \text{LeakyReLU}(F2)$ (Fonksiyon aynı)
5. Çıktı Projeksiyonu: $Y3 = X3 @ W3$
6. Son Aktivasyon: $\text{out} = \text{LeakyReLU}(Y3)$ (Fonksiyon aynı)

Formülün kilit noktası üçüncü adımdır: çarpımsal füzyonun sonucunu iki projeksiyonun toplamının mutlak değerine bölmek. Bu işlem iki şey yapar. Birincisi, değerlerin patlamasını engeller — örtük bir normalizasyon görevi görür. İkincisi, iki girdinin birbirine göre oranını çıkarır; iki sinyal uyumluysa (aynı yönde) çıktı stabildir, uyumsuzsa (zıt yönde) çıktı bu uyumsuzluğu yansıtır.

Mutlak değer değil, değişim önemlidir — RSBlock tam olarak bu değişimi ölçer.

Ağaç Yapısı: Hiyerarşik İndirgeme

RSNet, RSBlock'ları ikili ağaç yapısında organize eder. 8 elemanlı bir dizide süreç şöyle işler: Seviye 0'da 8 girdi ikiye bölünür ve 4 çıktı üretilir. Seviye 1'de bu 4 çıktı yeniden eşleştirilir ve 2 çıktı elde edilir. Seviye 2'de kalan iki çıktı birleştirilerek tek bir tahmin vektörüne ulaşılır. Üç seviye, sekiz girdiyi tek çıktıya indirger.

Her seviye kendi RSBlock'una sahiptir — aynı seviyedeki çiftler ağırlıkları paylaşır, farklı seviyeler farklı ağırlıklar kullanır. Seviye 0 yerel ilişkileri (komşu zaman adımları arası), üst seviyeler giderek daha global örüntüleri yakalar.

Bu yapının iki sonucu vardır. Birincisi, derinlik $O(\log_2 N)$ 'dir: 1024 elemanlı bir dizi sadece 10 seviyede işlenir. RNN'de aynı dizi 1024 sekansiyel adım gerektirir.

İkincisi, aynı seviyedeki tüm çiftler bağımsızdır ve paralel hesaplanabilir.

Parametre Yapısı

Her RSBlock üç adet öğrenilebilir ağırlık matrisi içerir: $W1$, $W2$ ve $W3$. Her biri $\text{input_dim} \times \text{input_dim}$ boyutundadır. Toplam parametre sayısı:

$$\text{Parametre} = 3 \times \text{dim}^2 \times \log_2(N)$$

8 girdi ve 64 boyut için: $3 \times 4096 \times 3 = 36.864$ parametre. Aynı koşulda bir LSTM yaklaşık 66.000 parametre kullanır.

Güçlü Yanlar

Çarpımsal İlişkilerde Güçlü Performans

RSNet'in formülü çarpımsal ilişkiler için doğal bir tümevarımsal önyargı taşır. 10 farklı sentetik görevde test edildiğinde, çarpımsal görevde sıfıra yakın kayıp (0.0000) elde eder. Aynı görevde LSTM 1.22, Mamba 2.05 val loss verir. Bu farkın önemli bir kısmı genelleştirme kapasitesinden kaynaklanır: RNN ailesi ve Mamba eğitim verisini ezberlerken (train loss düşük, val loss yüksek), RSNet overfit yapmadan öğrenir.

Eğitim Hızı

Sekansiyel bağımlılık olmadığı için RSNet daha kısa sürede eğitilir. Aynı veri ve koşullarda LSTM'den yaklaşık 8 kat, GRU'dan yaklaşık 15 kat daha kısa eğitim süresi ölçülmüştür. Bu fark, modelin sekansiyel adım gerektirmemesinden kaynaklanır.

Min/Max Yakalama

Dizideki en büyük ve en küçük değerleri yakalamada düşük kayıp elde edilir. Maksimum görevde 0.40, minimum görevde 0.44 val loss ölçülmüştür. Bu sonuçlar, aşırı değer tespiti ve anomali yakalama görevleriyle uyumludur.

Düşük Parametre Sayısı

LSTM'nin yaklaşık yarısı kadar parametre kullanır (36K vs 66K). Daha az parametre, sınırlı veri setlerinde overfit riskini azaltır. Çarpımsal görevlerde bu özellik avantaja dönüşür; ancak her görev türünde geçerli değildir.

DeneySEL Sonuçlar

RSNet, 10 farklı karakteristikteki sentetik görevde test edilmiştir. Parametreler: $\text{seq_len}=8$, $\text{dim}=64$, eğitim verisi=2048, doğrulama verisi=512, epoch=100.

Doğrusal Toplam: Train Loss 8.0055, Val Loss 7.9563, Eğitim Süresi 2.78 sn

Sinüs Kombinasyonu: Train Loss 9.6645, Val Loss 9.6784, Eğitim Süresi 2.54 sn

Maksimum (Max): Train Loss 0.3999, Val Loss 0.3971, Eğitim Süresi 2.34 sn

Ortalama (Mean): Train Loss 0.1251, Val Loss 0.1269, Eğitim Süresi 2.39 sn

Ardışık Farklar: Train Loss 1.9823, Val Loss 1.9818, Eğitim Süresi 2.36 sn

Karesel Toplam: Train Loss 17.8703, Val Loss 18.1633, Eğitim Süresi 2.34 sn

Çarpımsal: Train Loss 0.0000, Val Loss 0.0000, Eğitim Süresi 2.34 sn

Cos + Mutlak Değer: Train Loss 2.2434, Val Loss 2.1630, Eğitim Süresi 2.36 sn

Minimum (Min): Train Loss 0.4205, Val Loss 0.4285, Eğitim Süresi 2.37 sn

İlk ve Son Eleman: Train Loss 4.2310, Val Loss 4.2536, Eğitim Süresi 2.41 sn

Çarpımsal görevde sıfır kayıp, formülün çarpımsal doğasıyla bu görevin birebir örtüşmesinden kaynaklanır. Ortalama ve min/max görevlerinde de düşük kayıp elde edilirken, toplamsal görevlerde (doğrusal toplam, karesel toplam) kayıp yüksek kalmaktadır. Bu, formülün yapısal bir eğilimini yansıtır — bir güç değil, bir karakteristiktir.

Bilinen Sınırlamalar

Toplamsal görevlerde zayıf: Formülün çarpımsal doğası, toplama gerektiren görevlerde yapısal bir dezavantaj oluşturur. Doğrusal toplam ve karesel toplam görevlerinde val loss yüksek kalır.

Uzun dizilerde bilgi kaybı: Optimal performans aralığı seq_len 8-16'dır. Dizi uzunluğu 32'yi aştığında her seviyedeki hiyerarşik sıkıştırma bilgi kaybına yol açar ve performans düşer. Aynı koşullarda LSTM ve RNN uzun dizilerde daha iyi sonuç verebilir.

Kırılgan iç denge: RSBlock'un çarpım ve bölme dengesi hassastır. Positional encoding, LayerNorm ve Residual bağlantı gibi yaygın teknikler denenmiş, her birinin performansı kötüleştirdiği gözlemlenmiştir. Model dışarıdan yapısal müdahalelere karşı toleranssızdır.

Girdi kısıtı: Girdi sayısı (num_inputs) 2'nin kuvveti olmak zorundadır (2, 4, 8, 16, 32...).

Genel amaçlı değil: RSNet tüm sekans görevlerinde rekabetçi değildir. Toplamsal ve ardışık fark görevlerinde RNN ailesi belirgin biçimde daha iyi sonuç verir. RSNet yalnızca çarpımsal ve oransal ilişkilerin baskın olduğu verilerde avantaj sağlar.

Kullanım Alanları

RSNet'in güçlü olduğu görev profili — çarpımsal ilişkiler, oransal farklar, min/max yakalama — belirli uygulama alanlarıyla uyum gösterir. Ancak bu alanların her birinde RSNet'in pratik başarısı henüz gerçek dünya verileriyle doğrulanmamıştır; aşağıdaki alanlar formülün yapısından çıkan teorik uyumlardır.

Sensör anomali tespiti: Endüstriyel makinelerde titreşim, sıcaklık, basınç sensörleri arasındaki oransal kaymalar RSBlock'un formülüyle yapısal olarak uyumludur. Düşük parametre sayısı, edge cihazlarda çalışmayı mümkün kılabilir.

Radar ve sonar sinyal işleme: Ardışık taramalardaki yansıma desenlerinin karşılaştırması çarpımsal bir ilişkidir. Normal arka plan ile hedef girişi arasındaki uyumsuzluk, RSNet'in formülünün ölçmeye uygun olduğu bir sinyal türüdür.

Finansal volatilité: Portföy getirileri çarpımsaldır — ardışık günlerin getirilerinin çarpımı toplam getiriye verir. Volatilité kümelenmesi ve oransal sapma tespiti, formülle yapısal olarak uyumludur.

Biyomedikal sinyal karşılaştırma: EEG/EKG kanalları arası korelasyon değişimleri çarpımsal uyumsuzluk olarak ifade edilebilir.

Mimari Kararlar ve Gerekçeleri

RSNet'in tasarımında bilinçli olarak yapılmış kısıtlamalar vardır.

Normalizasyon katmanı yok: Formüldeki $|Y1 + Y2|$ bölme işlemi örtük normalizasyon sağlar. Ayrı bir LayerNorm veya BatchNorm eklenmemiştir. Bu, modeli basit tutar ama aynı zamanda formülü dışarıdan eklentilere karşı hassas kılar.

Seviye bazında ağırlık paylaşımı: Aynı seviyedeki tüm çiftler aynı RSBlock'u kullanır. Bu, CNN'deki ağırlık paylaşımına benzer bir tümevarımsal önyargı verir. Parametre verimliliği sağlar ama pozisyona özel ilişkileri öğrenmeyi kısıtlar.

Tek bağımlılık: RSNet yalnızca PyTorch gerektirir. Harici kütüphane, özel operatör veya ek altyapı yoktur. Tek bir Python dosyasıdır.

Ağırlık başlatma: Tüm ağırlık matrisleri ($W1, W2, W3$) 0.01 standart sapmayla küçük başlatılır. Bu tercih rastgele değildir: formülde bölme işlemi bulunduğu için büyük başlangıç ağırlıkları ilk iterasyonlarda $|Y1 + Y2|$ değerinde ani sıçramalara ve sayısal kararsızlığa yol açabilir. Küçük başlatma, eğitimin ilk adımlarında stabilite sağlar ve modelin kontrollü biçimde öğrenmeye başlamasına olanak tanır.

İlgili Çalışma

Hiyerarşik ikili ağaç indirgemesi fikri RSNet'e özgü değildir. WAT (Wave-Attractor-Tree, Berezkin 2026) da aynı ağaç yapısını kullanır ancak birleştirme operasyonu olarak GLU (Gated Linear Unit) + RMSNorm kullanır ve dil modelleme görevlerine odaklanır. RSNet ise çarpımsal oran ölçekleme formülü ve sinyal verisi odağıyla farklılaşır. İki mimari aynı yapısal prensibi paylaşır ama farklı problemlere farklı birleştirme mekanizmalarıyla cevap verir.

Değerlendirme

RSNet, genel amaçlı bir sekans modeli olmak iddiası taşımaz. Toplamsal görevlerde zayıftır, uzun dizilerde bilgi kaybeder, formülü dış müdahalelere karşı hassastır.

Bunları bilmek ve söylemek, modelin değerini azaltmaz — sınırlarını netleştirir.

RSNet'in değeri, belirli bir problem sınıfında — çarpımsal ilişkiler, oransal farklar, aşırı değer tespiti — daha az parametreyle ve daha kısa eğitim süresiyle sonuç vermesindedir. Sinyal verilerinde ardışık noktalar arası ilişkiyi yakalamak gereken ve az kaynak isteyen uygulamalar için bir seçenektir.

Makine öğrenmesinde hiçbir modelin tüm problemlerde üstün olmadığı matematiksel olarak kanıtlanmıştır. RSNet de bu ilkenin bir yansımasıdır: en iyi model en genel olan değil, problemi en doğru okuyandır.

Kaynak kod ve benchmark dosyaları: <https://github.com/merterenai/RSNet-Recursive-Scaling-Network>